

Rockchip RKAI 开发指南

文件标识：RK-KF-YF-A61

发布版本：V1.0.0

日期：2025-09-30

文件密级：☐绝密 ☐秘密 ☐内部资料 ☒公开

免责声明

本文档按“现状”提供，瑞芯微电子股份有限公司（“本公司”，下同）不对本文档的任何陈述、信息和内容的准确性、可靠性、完整性、适销性、特定目的性和非侵权性提供任何明示或暗示的声明或保证。本文档仅作为使用指导的参考。

由于产品版本升级或其他原因，本文档将可能在未经任何通知的情况下，不定期进行更新或修改。

商标声明

“Rockchip”、“瑞芯微”、“瑞芯”均为本公司的注册商标，归本公司所有。

本文档可能提及的其他所有注册商标或商标，由其各自拥有者所有。

版权所有 © 2025 瑞芯微电子股份有限公司

超越合理使用范畴，非经本公司书面许可，任何单位和个人不得擅自摘抄、复制本文档内容的部分或全部，并不得以任何形式传播。

瑞芯微电子股份有限公司

Rockchip Electronics Co., Ltd.

地址：福建省福州市铜盘路软件园A区18号

网址：www.rock-chips.com

客户服务电话：+86-4007-700-590

客户服务传真：+86-591-83951833

客户服务邮箱：fae@rock-chips.com

前言

概述

本文为大语言模型和视觉类大模型的快速验证和开发指南。

产品版本

芯片名称	内核版本
RV1126B	Kernel 6.1

读者对象

本文档（本指南）主要适用于以下工程师：

技术支持工程师

软件开发工程师

修订记录

版本号	作者	修改日期	修改说明
V1.0.0	Cherry Chen	2025-09-30	初始版本

目录

Rockchip RKAI 开发指南

1. 简介
2. 快速验证
 - 2.1 LLM快速验证
 - 2.2 VLM快速验证
3. 自定义模型
4. API详细说明
 - 4.1 LLM API
 - 4.2 VLM API

1. 简介

RKAI模块为SDK集成使用大语言模型（Large Language Model, LLM）和视觉类大模型（以下简称：Vision Language Model, VLM）的快速验证模块和适配示例，本模块代码开源，源码路径：

`app/rkai`，目录结构为：

```
tree rkai -L 1
rkai
├─ app_conf #配置文件和模型文件
├─ CMakeLists.txt
├─ common #通用代码
├─ LICENSE
├─ README.md
├─ rkai_LLM # LLM模型API源码
├─ rkai_VLM # VLM模型API源码
└─ samples # 适配用例
```

5 directories, 3 files

- `app_conf`为通用配置路径，该路径包括模型文件，模型配置文件，模型输入文件三个部分组成，该部分可以直接集成到板端以供使用。
- `common`为RKAI模块通用代码，例如 `CNPY` 等；
- `rkai_LLM`为LLM部署通用API；
- `rkai_VLM`为VLM部署通用API；
- `samples`提供LLM/Vision/VLM三个验证用例。

2. 快速验证

SDK默认自动编译了RKAI模块，且集成 `Qwen3-0.6B` 模型，供用户快速验证大模型流程。

2.1 LLM快速验证

LLM适配程序为 `rkai_LLM_Demo`，Usage如下：

```
Usage: rkai_LLM_Demo [options]
Options:
  --llm_model <path>    RKLLM model file
  --config <path>       Configuration ini file
Example:
  rkai_LLM_Demo --llm_model /usr/share/app_config/models/Qwen3-
0.6B_W4A16_RV1126B.rkllm \
  --config rkai_config.ini
```

默认推理命令：

```
rkai_LLM_Demo --config rkai_config.ini
```

程序中预制了4个问题，用户可通过数字输入进行选择，也可以终端输入问题。

```
*****可输入以下问题对应序号获取回答/或自定义输入*****
[0] 把下面的现代文翻译成文言文：到了春风和煦，阳光明媚的时候...
[1] 以咏梅为题目，帮我写一首古诗，要求包含梅花、白雪等元素。
[2] 上联：江边惯看千帆过
[3] 把这句话翻译成中文：Knowledge can be acquired from many sources...
[4] 把这句话翻译成英文：RK3588是新一代高端处理器...

*****
```

模型输出为两部分：1、模型回答；2、性能。

```
user: 0
把下面的现代文翻译成文言文：到了春风和煦，阳光明媚的时候...
I rkllm: reset chat template:
I rkllm: system prompt: <|im_start|>system\nYou are a helpful assistant.<|im_end|>\n
I rkllm: prompt_prefix: <|im_start|>user\n
I rkllm: prompt_postfix: <|im_end|>\n<|im_start|>assistant\n
W rkllm: Calling rkllm_set_chat_template will disable the internal automatic chat template parsing, including enable_thinking. Make sure your custom prompt is complete and valid.
robot: <think>
好的，用户让我把“到了春风和煦，阳光明媚的时候”翻译成文言。首先，我需要理解原句的意思。这句话描述的是春天的天气，特别是温暖的气候，可能用来描绘一个美好的季节。
接下来，我得考虑文言文的特点。文言文讲究用词准确、意象丰富，所以每个词都要有其特定的含义。比如“到”在文言中常表示时间或地点的到达，而“春风”和“阳光”都是自然景观，需要找到合适的词汇来表达。
然后，我需要确定翻译的结构。通常，
+-----+-----+
| Stage | Perf |
+-----+-----+
| TTFT  | 334.659 (ms) |
| TPS   | 14.117 (tokens/s) |
+-----+-----+
```

也可以自己转换模型后，使用 rkai_LLM_Demo 进行模型推理验证。详细说明见第三部分。

2.2 VLM快速验证

VLM实则为Vision和LLM，可以分开验证，也可以一起进行验证，由于模型内存占用大，不方便集成到SDK中。因此，用户快速验证VLM模型可以从以下网址进行模型下载。

Vision模型下载链接为：[Vision模型](#)；

LLM下载链接为：[LLM模型](#)。

将下载的模型push到板端 app_cofig/models 目录中。然后可以使用 raki_VLM_Demo 进行快速验证。Usage 如下：

```
Usage: rkai_VLM_Demo [options]
Options:
  --vision_model <path>  Vision RKNN model file
  --llm_model    <path>  LLM RKLLM model file
  --image_path   <path>  Input image file
  --config       <path>  Configuration ini file
Example:
./rkai_VLM_Demo --vision_model fastvlm-0.5b-fp16.rv1126b.rknn \
                --llm_model fastvlm-0.5B-w8a8_level0.rv1126b.rkllm \
                --image_path image.jpg --config rkai_config.ini \
```

如果将下载的模型推到 app_conf/models 路径下，则可以使用以下命令推理：

```
rkai_VLM_Demo --config rkai_config.ini
```

如果下载的模型推到其他路径下，则需要手动指定：

```
rkai_VLM_Demo --vision_model xxx.rknn \
               --llm_model xxx.rkllm \
               --config rkai_cfg.ini
```

模型输出为两部分：1、模型回答；2、性能。



3. 自定义模型

用户可以自行转换模型，通过 rkai_LLM_Demo 和 rkai_VLM_Demo 进行推理。模型转换工具下载链接：<https://github.com/airockchip/rknn-llm>。如果用户自定义模型，那么 rkai_cfg.ini 需要进行对应修改。

- 1. rkai_cfg.ini 中[llm_cfg]为LLM参数，包含模型超参数，用户可以通过调节参数来调整模型。参数如下：

参数	默认值	说明
llm_model	models/Qwen3-0.6B_W4A16_RV1126B.rkllm	可以通过外部参 --llm_model 定义
max_context_len	1024	最长上下文
max_new_tokens	128	最长输出tokens
skip_special_token	1	是否跳过特殊字符
base_domain_id	0	内存使用方式，默认为0
top_k	1	小于等于1

- 2. rkai_cfg.ini 中[vlm_cfg]为VLM参数，包含模型超参数，用户可以通过调节参数来调整模型。参数如下：

参数	默认值	说明
vision_model	models/fastvlm-0.5b-fp16.rv1126b.rknn	也可以通过外部参 -- vision_model 定义
llm_model	models/fastvlm-0.5B-w8a8_level0.rv1126b.rkllm	可以通过外部参 -- llm_model 定义
image_path	inputs/image_1024x1204.npy	支持输入jpg图片，通过 - image_path 指定
max_context_len	512	最长上下文
skip_special_token	1	是否跳过特殊字符
base_domain_id	0	内存使用方式，默认为0
top_k	1	小于等于1

3. rkai_cfg.ini 中[prompt]为系统prompt，用户自定义模型，这部分需要修改。参数如下：

参数	默认值	说明
system_prompt	< im_start >system\nYou are a helpful assistant. < im_end >\n	默认为qwen3的系统prompt
prompt_prefix	< im_start >user\n	通过模型的config文件可以获取
prompt_postfix	< im_end >\n< im_start >assistant\n	通过模型的config文件可以获取

4. rkai_cfg.ini 中[tensor]为VLM模型的图像占位符，用户自定义模型，这部分需要修改。参数如下：

参数	默认值	说明
img_start	< im_start >	图片占位符，可以在模型config中获取
img_end	< im_end >	同上
img_content	< im_content >	同上

4. API详细说明

用户可以自行调用API进行应用集成，API全开源，以下是API说明。

4.1 LLM API

对LLM模型进行初始化和反初始化的API如下：

API	rkai_llm_init
描述	LLM初始化
参数	rkaiCtxLLM* ctx： LLM句柄
	rkaiCfg* cfg :LLM参数配置

API	rkai_llm_release
描述	LLM返初始化

对LLM推理部署的API如下：

API	rkai_llm_run
描述	LLM推理
参数	rkaiCtxLLM* ctx： LLM句柄
	rkaiCfg* cfg :LLM参数配置

4.2 VLM API

VLM的Vision模型API：

API	rkai_vlm_vision_init
描述	Vision初始化
参数	const char *model_path： vision模型路径，为.rknn模型
	rkaiCfg* cfg :LLM参数配置

API	rkai_vlm_vision_release
描述	Vision返初始化

对Vision推理的API如下：

API	rkai_vlm_vision_run
描述	LLM推理
参数	rkaiCtxVision *rkai_ctx: 句柄
	void *img_data: 输入图片buffer, 为rgb888
	rkaiVisionToLLM *vtol: vision to llm 参数以及buffer

API	dump_tensor_attr
描述	dump模型的基本信息
参数	rknn_tensor_attr *attr: 模型tensor信息
	int32_t is_inputs: 是否dump输入

VLM的LLM API:

API	rkai_vlm_llm_init
描述	LLM初始化
参数	rkaiCtxLLM* ctx: LLM句柄
	rkaiCfg* cfg :LLM参数配置

API	rkai_vlm_llm_release
描述	LLM返初始化

对LLM推理部署的API如下:

API	rkai_vlm_llm_run
描述	LLM推理
参数	rkaiCtxLLM* ctx: LLM句柄
	rkaiCfg* cfg :LLM参数配置
	rkaiVisionToLLM *vtl:接收Vison过来的信息